



FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA

(FIAP)

**CURSO SUPERIOR DE TECNOLOGIA EM INTELIGÊNCIA
ARTIFICIAL**

GRUPO SÃO PAULO E INTERIOR

JONAS TADEU V. FERNANDES

LEVI PASSOS SILVEIRA MARQUES

RAPHAEL DA SILVA

RAPHAEL DINELLI NETO

YAN PIMENTAL COTTA

CardiolA:

Inteligência Artificial em séries temporais de saúde

SÃO PAULO

2026



**FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA
(FIAP)**

**CURSO SUPERIOR DE TECNOLOGIA EM INTELIGÊNCIA
ARTIFICIAL**

**GRUPO SÃO PAULO E INTERIOR
JONAS TADEU V. FERNANDES
LEVI PASSOS SILVEIRA MARQUES
RAPHAEL DA SILVA
RAPHAEL DINELLI NETO
YAN PIMENTAL COTTA**

CardiolA:

Inteligência Artificial em séries temporais de saúde

Trabalho acadêmico apresentado ao Curso Superior de Tecnologia em Inteligência Artificial da Faculdade de Informática e Administração Paulista (FIAP), como requisito para obtenção de nota na disciplina Cluster Computing, Computação Neuromórfica e Supercomputadores.

Tutor: Caique Nonato da Silva Bezerra

SÃO PAULO

2026



SUMÁRIO

1. INTRODUÇÃO	1
2. DESENVOLVIMENTO 1 – BASE DE DADOS, TRATAMENTO E FILTROS	2
2.1 Geração de base sintética	2
2.2 Caracterização das classes	3
2.3 Tratamento dos dados	3
3. DESENVOLVIMENTO 2 – REGRESSÃO LOGÍSTICA E LIF SPIKE CLASSIFIER	5
3.1 Regressão Logística.....	5
3.2 Modelo LIF Spike Classifier	6
4. DESENVOLVIMENTO 3: ANÁLISE OBTIDA.....	8
4.1 Comparação entre os modelos	8
4.2 Aplicabilidade no Cardiola	11
5. CONCLUSÃO.....	12
FONTES	13



TABELAS

TABELA 01 - Comparação entre os modelos	9
---	---



GRÁFICOS

GRAFICO 01 – Logistic Regression	9
GRAFICO 02 – LIF Spike Classifier.....	10
GRAFICO 03 – COMPARATIVO	10



FIGURAS

FIGURA 01 – Estrutura base de dados	2
---	---



SIGLAS

LIF – Leaky Integrate-and-Fire (Neurônio de Integração e Disparo com Vazamento)

BPM – Batimentos Por Minutos

GAN – Generative Adversarial Network (Redes Adversárias Generativas)

IA – Inteligência Artificial

GPT - Generative Pre-trained Transformer (Transformer generativo pré-treinado)



RESUMO

O presente trabalho apresenta desenvolvimento e a análise experimental de um pipeline de Inteligência aplicado à classificação de riscos em séries temporais sintéticas de saúde, no contexto do projeto CardiolA. O objetivo principal foi comparar o desempenho de um modelo tradicional de aprendizado de máquina, baseado em Regressão Logística, com um modelo neuromórfico simplificado do tipo *Leaky Integrate-and-Fire*, conhecido como *LIF*. A base de dados utilizada simula registros obtidos por um dispositivo vestível de monitoramento, contendo informações como temperatura, frequência cardíaca, nível de movimento, detecção de movimento, alerta de emergência e nível de risco. O processo metodológico envolveu carregamento dos dados via Google Drive, padronização das colunas, tratamento de valores ausentes, conversão de variáveis, análise exploratória, construção de janelas temporais, divisão entre treino e teste, treinamento dos modelos e avaliação por métricas de classificação. Os resultados indicaram desempenho máximo para ambos os modelos, com acurácia, precisão, revocação e *F1-score* iguais a 1,00, demonstrando que os dois métodos foram capazes de classificar corretamente as amostras sintéticas avaliadas. Conclui-se que a Regressão Logística apresenta maior simplicidade, interpretabilidade e aplicação prática em dados tabulares, enquanto o modelo *LIF* contribui como abordagem alternativa inspirada em funcionamento neuronal, sendo relevante para fins acadêmicos e experimentais em computação neuromórfica aplicada à saúde.

Palavras-chave: Inteligência Artificial. Séries temporais. Saúde. Regressão Logística. *Leaky Integrate-and-Fire*. CardiolA.



ABSTRACT

This work presents the development and experimental analysis of an Artificial Intelligence pipeline applied to risk classification in synthetic health time-series data within the Cardiola project. The main objective was to compare the performance of a traditional machine learning model, based on Logistic Regression, with a simplified neuromorphic-inspired model known as Leaky Integrate-and-Fire, or LIF. The dataset simulates records collected by a wearable monitoring device, including information such as temperature, heart rate, movement level, movement detection, emergency alert, and risk level. The methodological process involved data loading from Google Drive, column standardization, missing value treatment, variable conversion, exploratory analysis, time-window construction, train-test splitting, model training, and evaluation through classification metrics. The results indicated maximum performance for both models, with accuracy, precision, recall, and F1-score equal to 1.00, demonstrating that both methods correctly classified the evaluated synthetic samples. It is concluded that Logistic Regression provides greater simplicity, interpretability, and practical applicability for tabular data, while the LIF model contributes as an alternative approach inspired by neuronal behavior, being relevant for academic and experimental purposes in neuromorphic computing applied to health.

Keywords: Artificial Intelligence. Time series. Health. Logistic Regression. Leaky Integrate-and-Fire. Cardiola.



1. INTRODUÇÃO

A aplicação de Inteligência Artificial na área da saúde tem se tornado cada vez mais relevante devido ao crescimento de dispositivos vestíveis, sensores biométricos e sistemas de monitoramento remoto. Equipamentos como *smartwatches* e dispositivos embarcados permitem a coleta contínua de sinais fisiológicos, como frequência cardíaca, temperatura corporal e informações relacionadas ao movimento do usuário. Esses dados, quando organizados em séries temporais, podem ser utilizados para identificar padrões, detectar alterações relevantes e classificar situações de risco.

Nesse contexto, o projeto CardiolA propõe uma simulação de monitoramento inteligente de saúde, utilizando dados sintéticos para representar o comportamento de um sistema vestível. O experimento apresentado no notebook analisado tem como finalidade comparar duas abordagens distintas de classificação: uma tradicional, baseada em Regressão Logística, e outra inspirada em computação neuromórfica, baseada no modelo *Leaky Integrate-and-Fire*.

A Regressão Logística foi utilizada como modelo de referência por ser simples, interpretável e amplamente empregada em problemas de classificação. Já o modelo *LIF* foi utilizado por representar, de forma simplificada, o comportamento de neurônios biológicos, acumulando sinais de entrada ao longo do tempo e produzindo respostas baseadas em potenciais de membrana e geração de impulsos.

O objetivo deste relatório é apresentar o processo de carregamento e tratamento dos dados, explicar a aplicação dos modelos, analisar os resultados obtidos e discutir as conclusões do experimento.



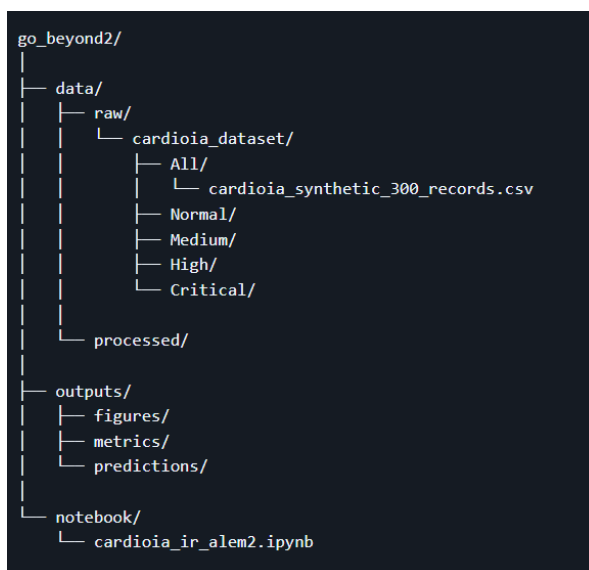
2. DESENVOLVIMENTO 1 – BASE DE DADOS, TRATAMENTO E FILTROS

2.1 Geração de base sintética

Para a realização do experimento, foi proposta a criação de uma base de dados sintética com 300 registros simulados, gerados na plataforma *GAN ChatGPT*. Esses dados representam leituras geradas por um dispositivo vestível de saúde, inspirado em um *smartwatch*. A base foi estruturada com quatro classes de risco: *normal*, *médium*, *high* e *critical*. Cada classe foi planejada com aproximadamente 75 registros, garantindo uma distribuição equilibrada entre os níveis de risco.

A estrutura da base foi definida com os seguintes campos:

FIGURA 01 – Estrutura base de dados



Fonte: Própria Autoria

O notebook foi estruturado para acessar os arquivos a partir do Google Drive, utilizando uma organização de diretórios própria do projeto. A estrutura utilizada contempla pastas para dados brutos, dados processados, figuras, métricas e previsões, permitindo melhor organização dos artefatos gerados durante a execução do pipeline.



2.2 Caracterização das classes

A classe normal representa leituras estáveis, com temperatura dentro da faixa esperada, batimentos cardíacos moderados e presença de movimento compatível com um usuário em situação comum. A classe *médium* representa pequenas alterações, como aumento discreto da frequência cardíaca ou temperatura levemente elevada. A classe *high* simula situações mais relevantes, como batimentos acima do esperado, temperatura elevada e redução significativa de movimento. A classe *critical* representa cenários de maior gravidade, normalmente associados ao acionamento do botão de emergência, batimentos elevados e baixo nível de movimento.

A utilização do botão de emergência na classe crítica está alinhada com as etapas anteriores do Cardiola. Esse botão representa uma ação voluntária do usuário diante de desconforto, taquicardia ou percepção de risco. Dessa forma, ele se torna uma variável importante na classificação de eventos críticos.

2.3 Tratamento dos dados

A etapa de pré-processamento também incluiu a conversão de variáveis booleanas, tratamento de valores ausentes, conversão de valores numéricos, padronização das classes de risco e limitação dos valores em faixas aceitáveis. A temperatura foi limitada entre 30 °C e 45 °C, a frequência cardíaca entre 30 BPM e 220 BPM, e o nível de movimento entre 0 e 1.

Após o tratamento, os dados foram ordenados cronologicamente e salvos no diretório `data/processed`, gerando o arquivo processado `cardioia_processed_records.csv`. O notebook também apresentou uma análise exploratória inicial por meio de gráficos de distribuição das classes, série temporal da frequência cardíaca, série temporal da temperatura e histogramas das variáveis fisiológicas.

A distribuição das classes apresentada no notebook indicou equilíbrio entre os quatro níveis de risco: *normal*, *medium*, *high* e *critical*. Esse equilíbrio é importante para evitar que o modelo aprenda de forma enviesada em favor de uma classe



majoritária. As visualizações temporais mostraram variações progressivas nos sinais, especialmente na frequência cardíaca e na temperatura, coerentes com a proposta de simulação de diferentes níveis de risco.

Além disso, foi realizada a construção de janelas temporais. Essa etapa é fundamental porque os modelos não trabalharam apenas com registros isolados, mas com blocos sequenciais de dados. Cada janela agrupou registros consecutivos e extraiu estatísticas como média, desvio padrão, valor mínimo, valor máximo, amplitude, inclinação, primeiro valor e último valor. Dessa forma, o modelo passou a receber informações mais representativas do comportamento temporal dos sinais.



3. DESENVOLVIMENTO 2 – REGRESSÃO LOGÍSTICA E LIF SPIKE CLASSIFIER

3.1 Regressão Logística

A Regressão Logística foi utilizada como modelo tradicional de aprendizado de máquina para classificação dos níveis de risco. Embora seja um algoritmo simples, ela é amplamente empregada em problemas de classificação por apresentar boa interpretabilidade, baixo custo computacional e facilidade de implementação.

No experimento, a Regressão Logística não recebeu os dados brutos diretamente. Em vez disso, foram utilizadas as características estatísticas extraídas das janelas temporais. Essas características representam o comportamento dos sinais ao longo de um intervalo, permitindo que o modelo avalie tendências e variações, não apenas valores pontuais.

Antes do treinamento, as variáveis de entrada foram padronizadas com *StandardScaler*, processo que transforma os dados para uma escala comum. Essa etapa é importante em modelos lineares, pois evita que variáveis com escalas maiores influenciem excessivamente o processo de aprendizado.

O modelo foi configurado com penalização L2, parâmetro $C = 0.25$, balanceamento automático de classes e limite máximo de 2000 iterações. A penalização L2 contribui para controlar a complexidade do modelo, reduzindo pesos excessivos e tornando a classificação mais estável.

Após o treinamento, a Regressão Logística apresentou desempenho máximo nas métricas avaliadas. O relatório de classificação exibido no notebook indicou valores iguais a 1,00 para precisão, revocação e *F1-score* em todas as classes. A matriz de confusão também confirmou que todas as amostras foram classificadas corretamente, sem erros entre as categorias *normal*, *medium*, *high* e *critical*.

Esse resultado demonstra que, para a base sintética utilizada, as características extraídas das janelas foram suficientes para separar claramente os níveis de risco. A Regressão Logística, portanto, apresentou excelente desempenho, mantendo como principal vantagem sua simplicidade e facilidade de interpretação.



3.2 Modelo LIF Spike Classifier

O segundo modelo avaliado foi o *Leaky Integrate-and-Fire*, ou *LIF*. Trata-se de um modelo inspirado no funcionamento simplificado de neurônios biológicos. Em termos gerais, o neurônio *LIF* acumula sinais de entrada ao longo do tempo em uma variável chamada potencial de membrana. Quando esse potencial ultrapassa um determinado limiar, ocorre a geração de um impulso, ou *spike*, e o potencial é reiniciado.

No notebook, o modelo *LIF* foi implementado de forma simplificada para transformar sinais fisiológicos em uma corrente de entrada. Essa corrente foi calculada a partir da frequência cardíaca, temperatura e movimento. A frequência cardíaca recebeu maior peso, seguida da temperatura e do movimento. A lógica utilizada considera que maior frequência cardíaca, maior temperatura e menor movimento podem aumentar a intensidade do sinal de entrada.

A partir dessa corrente, o modelo simulou o comportamento do potencial de membrana ao longo da janela temporal. Foram extraídas características neuromórficas como:

- quantidade de *spikes*;
- taxa de *spikes*;
- tensão média;
- tensão máxima;
- tensão final;
- corrente média;
- corrente máxima;
- inclinação da corrente.

Essas características foram utilizadas para classificar as janelas por meio de protótipos de classe. O modelo calculou um vetor médio para cada classe durante o treinamento e, na etapa de teste, classificou cada nova janela com base na menor distância em relação aos protótipos aprendidos.

Os gráficos de interpretação do *LIF* apresentados no notebook mostraram a corrente de entrada e o potencial de membrana do neurônio ao longo de uma janela



temporal. A corrente apresentou oscilações conforme as variações dos sinais fisiológicos. Já o potencial de membrana acumulou gradualmente a influência desses sinais, mantendo-se abaixo ou próximo do limiar definido.

Assim como a Regressão Logística, o modelo *LIF* apresentou desempenho máximo nas métricas avaliadas. A matriz de confusão indicou classificação correta de todas as amostras do conjunto de teste. Isso demonstra que a abordagem neuromórfica simplificada foi capaz de representar adequadamente os padrões presentes na base sintética.

A principal contribuição do modelo *LIF*, neste trabalho, não está apenas no desempenho quantitativo, mas na demonstração de uma abordagem alternativa inspirada em sistemas biológicos. Enquanto a Regressão Logística atua diretamente sobre características estatísticas, o *LIF* introduz uma camada de interpretação temporal baseada em corrente, potencial e disparos neuronais.



4. DESENVOLVIMENTO 3: ANÁLISE OBTIDA

A análise comparativa entre os modelos mostrou que tanto a Regressão Logística quanto o *LIF Spike Classifier* alcançaram desempenho equivalente no conjunto de teste. As métricas finais apresentaram valores iguais a 1,00 para acurácia, precisão ponderada, revocação ponderada e *F1-score* ponderado.

A matriz de confusão da Regressão Logística indicou que todas as amostras foram corretamente classificadas em suas respectivas classes. Da mesma forma, a matriz de confusão do modelo *LIF* demonstrou ausência de erros de classificação. O gráfico comparativo final confirmou o desempenho idêntico entre os dois modelos.

A partir desses resultados, pode-se interpretar que a base sintética apresenta padrões bem definidos entre as classes de risco. Isso significa que as variáveis utilizadas e as características extraídas das janelas temporais foram suficientes para diferenciar claramente as categorias *normal*, *medium*, *high* e *critical*.

Do ponto de vista prático, a Regressão Logística se destaca pela simplicidade, rapidez de treinamento e facilidade de interpretação. Esse modelo é mais apropriado para situações em que se deseja uma solução objetiva, explicável e de fácil implementação em sistemas convencionais.

Por outro lado, o modelo *LIF* se destaca por introduzir uma perspectiva neuromórfica ao problema. Embora seja mais complexo conceitualmente, ele permite representar os sinais de saúde como estímulos temporais acumulados, aproximando a análise computacional de uma lógica inspirada em funcionamento neuronal.

A comparação entre os modelos pode ser resumida da seguinte forma:

4.1 Comparação entre os modelos




TABELA 01 - Comparação entre os modelos

Critério	Regressão Logística	LIF Spike Classifier
Tipo de abordagem	Aprendizado de máquina tradicional	Modelo neuromórfico simplificado
Entrada principal	Características estatísticas das janelas	Sequências temporais convertidas em corrente
Interpretação	Mais simples e direta	Mais conceitual e inspirada em neurônios
Custo computacional	Baixo	Moderado
Aplicação prática	Mais imediata	Mais experimental
Resultado obtido	Desempenho máximo	Desempenho máximo

Fonte: Própria Autoria


GRAFICO 01 – Logistic Regression



Fonte Própria Autoria




GRAFICO 02 – LIF Spike Classifier



Fonte Própria Autoria

GRAFICO 03 – COMPARATIVO



Fonte Própria Autoria

A análise permite afirmar que ambos os modelos foram adequados para o cenário sintético proposto. Entretanto, a Regressão Logística apresenta maior aplicabilidade prática para um sistema inicial de classificação de risco, enquanto o *LIF* possui maior valor exploratório, acadêmico e conceitual.



É importante destacar que, por se tratar de uma base sintética, os resultados não devem ser interpretados como evidência clínica. O experimento é válido para fins de comparação metodológica, estudo de pipeline de IA e exploração de modelos aplicados a séries temporais de saúde.

4.2 Aplicabilidade no CardiolA

No projeto CardiolA, a Regressão Logística pode ser utilizada como modelo inicial para classificação de risco em sistemas de monitoramento. Ela permite identificar rapidamente padrões associados a estados normais, moderados, elevados e críticos. Sua simplicidade facilita a explicação, validação e documentação do experimento.

O modelo *LIF*, por sua vez contribui como uma abordagem exploratória e bioinspirada. Ele demonstra como sinais vitais podem ser tratados como estímulos temporais, aproximando a análise de conceitos utilizados em redes neurais pulsadas e computação neuromórfica. Mesmo sendo uma visão simples, o modelo agrega valor conceitual ao projeto por ir além da classificação tradicional.



5. CONCLUSÃO

O presente trabalho apresentou a construção e análise de um pipeline de Inteligência Artificial para classificação de riscos em séries temporais sintéticas de saúde no contexto do projeto CardiolA. O processo incluiu carregamento dos dados a partir do Google Drive, tratamento e padronização das variáveis, análise exploratória, construção de janelas temporais, treinamento de modelos e avaliação por métricas de desempenho.

A Regressão Logística demonstrou excelente desempenho, alcançando resultados máximos em todas as métricas avaliadas. Seu principal diferencial está na simplicidade, interpretabilidade e facilidade de aplicação em sistemas baseados em dados tabulares.

O modelo *Leaky Integrate-and-Fire* também apresentou desempenho máximo, demonstrando que uma abordagem inspirada em funcionamento neuronal pode ser utilizada para transformar sinais temporais em características relevantes para classificação. Sua principal contribuição está na representação dos sinais fisiológicos como correntes e potenciais acumulados ao longo do tempo.

A comparação final mostrou que ambos os modelos foram capazes de classificar corretamente as amostras da base sintética. No entanto, cada abordagem possui finalidades distintas: a Regressão Logística é mais indicada para implementação prática inicial, enquanto o *LIF* é mais adequado para estudo experimental de computação neuromórfica.

Conclui-se que o experimento cumpriu seu objetivo de comparar duas abordagens de classificação aplicadas a dados sintéticos de saúde. Como trabalho futuro, recomenda-se testar o pipeline com bases mais variadas, incluir ruídos realistas, ampliar o número de amostras, comparar outros modelos de aprendizado de máquina e avaliar a solução em cenários mais próximos de aplicações reais de monitoramento vestível.



FONTES

Faculdade de Informática e Administração Paulista (FIAP). Cérebro de Silício: Neuromorfismo, Memristores e Simulações Biológicas. São Paulo: 2026.

Faculdade de Informática e Administração Paulista (FIAP). Cérebro de Silício na era dos Chips Neuromórficos. São Paulo: 2026.

NEURONAL DYNAMICS. Neuronal Dynamics: Python Exercises

Disponível em: <https://neuronaldynamics-exercises.readthedocs.io/en/latest/index.html#>. Acesso em: 10/05/2026.

SCKIT LEARN. Logistic Regression.

Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html. Acesso em: 10/05/2026.

